AI Safety Challenge

Çıktı: AI F

Ad Soyad | Grup | Tarih

Kavram — Prediction ≠ Safety: Yapay zekâ bir karar üretir; güvenliği garanti eden mimari YZ'nin **dışında** tanımlanmalıdır.
Araçlar: fail-safe · human override · monitoring · confidence threshold · fallback.

*Senaryo: PaketPro'ya YZ'li görsel paket kontrolü **eklenmesi planlanıyor** — proje aşaması değerlendirmesi yapıyorsunuz.*

Kamera → YZ Modeli → OK / RED → Ret mekanizması → Hat hızı

Görev — üç başarısızlıkta güvenli davranış

1. **Model yanlış sınıflandırdı:** Kusurlu parçaya OK verdi. Sistem ne yapmalı? İkinci kontrol / insan onayı var mı?
   - Sistemde bağımsız fiziksel sensörle (lazer yükseklik sensörü / tartım) ikincil kontrol yapılır. YZ ile sensör çelişirse parça otomatik olarak Ret (REJ) hattına aktarılır (Fail-Safe).
   - İkinci kontrol vardır; ayrılan parçayı operatör inceler ve karar verir (Human Override).

2. **Girdi manipüle edildi:** Kamera verisi bozuk/sahte. Nasıl fark edilir? Şüpheli girdide ne yapılır?
   - Fark edilme: Kare düşmesi (FPS kaybı), görüntü donması, zaman damgası uyumsuzluğu veya piksel anomali denetimiyle (Monitoring).
   - Yapılacak: Sistem kör çalıştırılmaz; veri akışı şüpheli olduğu anda işlemdeki kutu güvenli tarafta kalınarak Ret hattına itilir, görsel alarm verilir (Fail-Safe).

3. **Confidence düştü:** Model "emin değilim" diyor. Eşik ne olmalı? Altında: dur / insana sor / fallback?
   - Eşik: Güvenlik ve kalite riski nedeniyle %90 olmalıdır.
   - Eşik Altı Davranış: Hat aniden durdurulmaz (Fallback devreye girer); şüpheli paket doğrudan ret/karantina bandına ayrılır ve operatör incelemesine yönlendirilir (İnsana sor / Human-in-the-loop).

Karar tablosu — AI Fail-Safe Decision

Başarısızlık	Tanımladığınız güvenli davranış (hangi kavramla?)
Model yanlış sınıflandırdı	Fiziksel sensörle (lazer/tartım) ikinci kontrol yapılır; uyumsuzlukta parça ret hattına atılır (Fail-Safe & Human Override)
Girdi manipüle edildi	Zaman damgası ve görüntü donma takibi yapılır; bozuk karede paket doğrudan reddedilir ve alarm üretilir (Monitoring & Fail-Safe)
Confidence düştü	Eşik <%90 ise paket hattan ret/karantina konveyörüne yönlendirilir, operatör onayına bırakılır (Confidence Threshold & Fallback).

Bu föyün çıktısı **AI Fail-Safe Decision** → Evidence Pack **EP 03 + EP 15** başlığına oturur.